

文脉：传统文化热门视频弹幕六维读法

团队名称：（提交时填写）

团队编号：（提交时填写）

作品名称：文脉弹幕六维读法

参赛方向：开源赋能的 AI 应用创新

作品形态：数据与知识工具，附带离线可视化

日期：2026 年 10 月 8 日

作品简介：做文化传播和美育复盘的人，要分清热门传统文化视频下的观众是在评价制作、补知识、谈审美，还是想去学。人工按六维十七类编码看不过来，正负情感又对不上这十七类。文脉把码表做成可复算流程：规则负责可解释编码，字符模型对照规则没盖住的说法，离线页面画出时间、符号和五组载体的差异。2026-10-07 的当前公开池有 833,104 条，其中 38,566 条至少落入一类。核心句上规则精确匹配为 1。码表、统计和页面以 MIT 开放，弹幕正文不进仓库。

一、作品概述

1. 背景与问题

做文化传播、美育和平台研究的人，想知道观众在热门传统文化视频里究竟完成了哪种接收：是在评价制作，是在补知识、发问，是在共情、自豪或回想，是在谈审美，是在辩论传承，还是产生了学习、转发和实践。热门视频的弹幕量级使人工编码不可行。通用情感正负向又对不上这十七类。

使用的人是做这项研究或复盘的学生和内容团队。场景是：先按写明的热门线列出视频，拉下播放器当前公开弹幕池，再得到可复核的计数、时间曲线和一张离线页面。不替代人工把某一条句子判成最终学术结论。

2. 目标、方向与形态

目标是把下面这套码表做成可复算流程。

1. 作品评价：制作认可、制作诟病、观看体验
2. 知识认知：文化符号提及、知识补证、知识疑问
3. 情感认同：古今共情、文化自豪、文化记忆
4. 审美鉴赏：传统美学褒扬、审美辨析
5. 传播思辨：传承困境探讨、古今适配讨论、文化比较
6. 传承意向：学习意愿、传播意愿、实践印证

申报方向是「开源赋能的 AI 应用创新」。形态是数据与知识工具：规则码表、字符级多标签模型、时间与符号统计、离线 HTML。可选步骤是用开源中文编码器微调同一套标签。

3. 核心亮点

- 十七类是多标签。一条弹幕可以同时评价制作和点名器物。占比相加允许超过 100%，页面上写明了。
- 观看体验（加载、字幕、时长）和制作质量分开。知识性纠错进知识补证，不自动写成制作诟病。
- 符号用词表，并且长名称优先，避免「清明上河图」被拆成「清明」。
- 进度曲线按视频等权，只统计不少于 30 条弹幕的片子，避免一条超长视频淹没其余。
- 字符模型专门用来暴露规则的缺口，不把规则分数说成真实弹幕上的人工一致率。
- 运行时不调用闭源模型接口。弹幕正文不进仓库。

二、需求分析与总体方案

1. 需求分析

现有做法通常是抽一小段人工编码，或把弹幕做成正负情感。前者盖不住热门视频，后者回答不了「这是在补证、在比较文化，还是想去学」。优先级是：先把十七类的边界写成可测试的操作化定义，再在全量上出分布，最后用模型指出定义还盖不住的说法。

2. 总体方案

热门线与标题条件

- 当前公开弹幕池（本地，不入库）
- 规则多标签 + 符号词表
- 视频等权进度曲线、片内维度承接、5 秒问答邻近、视频内突发
- 每万条密度、组内构成、空池、二级类抬升、停留与换维、组间残差
- 类共现与点互信息、载体相对抬升、头部视频集中度、符号与维度、发送时刻、残差二字
- 字符模型对照规则银标，并记下模型多标和规则独有
- summary.json + 离线 HTML

可选分支：银标 jsonl 接到 hfl/chinese-macbert-base。

3. 可行性与成本

CPU 路径只依赖 Python 和 numpy。不训练大模型，不需要专用硬件。GPU 脚本是同一标签体系的后续步骤，默认检测到没有 CUDA 就退出。列清单和拉弹幕受公开接口速率限制，可以中断后续跑。

三、AI 技术与开源及第三方资源

1. AI 在哪里起作用

规则短语负责可解释的高精确编码。它单独不够：说法一换词就会漏。字符 n-gram、一对多逻辑回归用团队自写的 90 句训练，在核心句上检查这种漏法，并在难句上看它会不会误伤。真实弹幕上，模型只对照规则银标，用来量规则和模型差多远，不把这份分数当成人工金标。

有 GPU 时，wenmai/train_gpu.py 把同一份标签接到开源中文编码器，损失是多标签分类。这一步不在默认成绩里，避免没有 GPU 就无法复核。

2. 开源及第三方资源

见文末清单。运行时的模型计算发生在本机 numpy 或可选的 transformers 里，不把弹幕送到第三方生成式接口。

3. 自主开发与权利边界

团队写的是码表、短语与符号的边界、时间与共现统计、抽样、可视化、测试、GPU 训练脚本的数据接口，以及本报告。numpy、Python、可选的 torch / transformers / MacBERT 权重都不是团队训练出来的底座。弹幕是平台上的用户文字，只在本地读取，不作为开放数据集发布。

开发过程使用了编程代理起草代码和报告段落。核心句、难句、短语和测试是仓库里的约束；下文的分数来自本机运行 `python -m wenmai eval`，不是代理口中的数。

4. 融合方式

开源数值库提供可训练的线性分类器，开源编码器提供可选的上下文表示，团队的码表提供标签空间。去掉码表，模型没有这十七类；去掉模型，就只剩一份无法对照缺口的词表。页面直接画出两者的分数差别。

四、设计与实现

1. 核心功能

- `python -m wenmai eval`：自写句子上的规则与字符模型分数。
- `python danmaku/crawl.py --list-only`：按热门线列出视频。检索词中断后可从 `_partial.json` 续跑。
- `python danmaku/crawl.py`：拉当前公开池。已完成的视频会跳过。
- `python -m wenmai analyze`：写出不含原文的摘要，并在输出目录留下不入库的银标和例句。
- `python -m wenmai render`：生成单文件 HTML，浏览器直接打开。
- `python -m wenmai.train_gpu`：可选微调。

一条弹幕的规则顺序是：符号词表、制作认可（强短语或「创作方面 + 正向词」，遇拖沓、混乱等阻断词则不用组合规则）、制作诟病、观看体验、知识补证（含「不是……而是」）、知识疑问、其余短语类、文化比较的双向窗口。观看体验不把「字幕组辛苦了」收进去。

2. 关键实现

进度：多分 P 时用 `timeline_ms` 把前几 P 的时长接上。曲线横轴是片头到片尾的 20 等分。每个非空等分里，先算「落入该维的弹幕 / 该等分弹幕」，再对视频取平均。播放器池按六分钟一段拉全。中间段为空时仍继续往后拉，不把后面的段丢掉。

问答邻近：某一秒里的知识疑问，若同一秒到其后 5 秒内出现知识补证，这些疑问各记 1。不使用用户标识。

突发：每个视频切 10 段。某一类在一段里至少 3 条，且不低于该视频该类均值的 3 倍，记一次。视频总条数少于 6 的不记。

相对抬升：某一载体里该维占弹幕的比例，除以全库同一比例。1 是和全库一样。二级类用同一算法，页面只画该组至少 20 条、且不低于全库 1.3 倍的类。

每万条：该维条数除以全部弹幕，再乘以 10000。组内构成的分母是该组六个维度的命中次数之和。

停留：不少于 30 条弹幕的片子按 20 段看哪一维最多，停留率是下一格仍为同一维的比例。换维只列出不少于 8 次的交接。

组间残差：未编码且不是纯笑声的句子里抽二字（哈希抽样），某一组的二字比例减去其余组，再除以合并比例的标准误。功能词不参与。z 大于 2、该组至少 12 次、至少出现在 8 支视频里，并且单支不超过一半，才留下。这不是主题模型。

集中度：每一类里，贡献最多的一支视频占该类条数的比例，另附赫芬达尔指数。头部占比很高时，这个数不能当成所有热门视频的共性。

片内承接：不少于 30 条弹幕的片子按 20 段看哪一维最多，再数相邻两段从哪一维接到哪一维。

点互信息：两类一起出现的比例，除以两类各自比例的乘积，再取对数。它和 Jaccard 一起看：一个看重叠有多大，一个看是否高于偶然。

符号与维度：点到某一类符号时，同一条弹幕还落在哪些一级维。

发送时刻按东八区，已编码和未编码各自归一。弹幕模式只计滚动、顶部、底部等播放器字段。

残差：未编码、也不是纯笑声的句子里抽二字，用来看码表还缺什么，不称为主题模型。

银标抽样上，字符模型还会分开计数「模型多标」和「规则有而模型无」。这是规则和模型互相暴露缺口，不是人工一致率。

另一批未编码弹幕不进入这次训练。字符模型用团队自写句加上其余银标来训，再数这批句子里模型标出了哪些类。摘要和页面只留各类次数。这些次数不是人工金标。只有说法本身落在某一类的定义里，才补短语，并且补一条核心句，让 `python -m wenmai eval` 的核心句精确匹配仍为 1。

点名某个符号时，同一条弹幕还落在哪一维。点名本身就会落入知识认知，所以对照是所有点到符号的弹幕，不是全库。至少 20 次点名才计算。倍数不低于 1.3、且该维至少 8 条，才写成这个名字额外绑在知识认知以外的某一维上。

每一支片子单独给出占优维、六维条数、相对它所在载体的抬升、词表里点到的符号，以及当前池是否为空。空池不编造接收。

稀有类同时给出条数、出现的视频数和头部占比。没有一支片子以某一维为占优维时，页面直接写 0。稀少不解释成观众没有这个想法。

有 GPU 时，`train_gpu.py` 在训练集上按类搜索阈值，银标验证集用这组阈值，并在同一套 33 条核心句和 8 条难句上另算分数。分数旁边写明：这是对照码表，不是从弹幕里抽出来的人工金标。没有 CUDA 时脚本退出。权重不提交。打分和按类搜阈值的逻辑在没有 torch 时仍有单元测试。

3090 24GB、约 3 小时加上 `--hours` 和本地弹幕池。种子 0 的 `hfl/chinese-macbert-base` 写下银标分数、核心句和难句的逐句差异、已编码弹幕相对规则的多标和漏标、同一批 1,500 条缺口的各类次数，以及训练机上的边际清单。全量前向的 batch 按 24GB 取 256，训练 batch 仍是 16。预算内接着各跑一轮 `hfl/chinese-macbert-large` 和 `hfl/chinese-roberta-wwm-ext`，其余时间重复主模型的种子，范围写在 `budget.json`。重复种子的权重不保存。报告只采用主模型种子 0。2026-10-08 在 RTX 3090 上跑完，程序读到 23.6GB；进程内预算 7,808 秒，实际 7,735 秒。采用的分数见第五节，原文在 `wenmai/results/gpu-seed0.json` 和 `wenmai/results/gpu-budget.json`。

字符模型：一字、二字、三字，哈希到 32768 维，稀疏随机梯度，阈值在训练集上按类搜索。训练句与 `gold.json` 的句子不允许相同，测试会检查。

3. 过程与生成式工具

见第三节。代理起草的代码经过本机测试。附录里的全量分布来自本机 `analyze` 写出的 `summary.json`。

五、成果展示与效果验证

1. 怎么打开

无弹幕时：

```
python -m wenmai eval
```

有本地弹幕池时，按 `wenmai/README.md` 生成 `wenmai/results/index.html`。

2. 验证方法

- 核心句 33 条：十七类都至少出现一次，另有空标签句子，防止把「哈哈」「好看」收进六维。要求规则与标注完全一致。补进「讲得真好」「古代人也」「字幕不错」时，各加了一条核心句。
- 难句 8 条：换一种说法，用来展示规则的召回上限，不拿来充当成绩。
- 字符模型：90 句自写训练数据，同一批核心句和难句上另算分数。符号词仍不放进模型的记忆里。
- 真实弹幕：全量拉取后的计数、曲线和分组见 summary.json。银标对照分数只说明模型和规则是否接近。

3. 已经跑出来的结果

命令：python -m wenmai eval。随机种子固定为 0。

对照	条数	精确匹配	微平均 F1	宏平均 F1
规则·核心句	33	1.000	1.000	1.000
规则·难句	8	0.000	0.200	0.111
字符模型·核心句	33	0.879	0.898	0.902
字符模型·难句	8	0.125	0.300	0.296
MacBERT-base·核心句	33	0.879	0.894	0.792
MacBERT-base·难句	8	0.375	0.571	0.444

规则在核心句上没有漏，也没有多标。难句 8 条里，7 条完全没有命中设计中的类；「奶奶那辈人还会这门活」只命中了文化记忆，没有命中实践印证。难句微平均 F1 为 0.200，因为 9 个标签实例里只对上 1 个。这是码表的边界，不是全量弹幕的准确率。

字符模型在核心句上精确匹配 29/33。4 条不一致是：3 条漏了「文化符号提及」（后母戊鼎、昆曲、青铜器），1 条在「为什么这么卡」上多标了知识疑问和审美辨析，观看体验仍然标对。符号是开放词表，不放进字符模型的记忆里。难句 8 条里，模型只把「突然就懂古人了」整句对上。其余难句仍会漏掉设计中的类，或在对上的类旁边多标。这不是全量准确率。

MacBERT-base 种子 0 的银标宏平均 F1 为 0.798。银标 4,616 条按种子 0 打乱后取 10%：训练 4,155 条，验证 461 条。这和字符模型的哈希划分不是同一刀。十七类里，传承困境探讨为 1.000，文化记忆 0.983，传播意愿 0.970；古今适配讨论和文化比较在这份验证集上为 0。核心句也是 29/33，漏的句子和字符模型不同：「剪辑太拖沓，讲解也很混乱」漏了制作诟病、多标了制作认可；「用国潮把老手艺年轻化，才好走进现代」漏了古今适配讨论；「和西方的庆典相比，这边的礼制完全不同」漏了文化比较；「补充一下，青铜器的正名应以铭文为准」漏了知识补证，文化符号提及仍在。难句整句对上 3 条：「有人能讲讲这为啥叫这个名字」「突然就懂古人了」「想把这门手艺接下去」。其余 5 条：「这镜摇得稳，光也听话」漏了制作认可；「跟东瀛那边的礼不一样」漏了文化比较；「字小到根本看不清在说什么」漏了观看体验；「老工艺和现在的城市生活接不上」漏了古今适配讨论、多标了制作认可；「奶奶那辈人还会这门活」漏了实践印证，文化记忆仍在。这些分数对照码表和自写句。

银标验证集上，模型多标最多的是文化符号提及 12、传统美学褒扬 5、实践印证 4；规则有而模型无最多的是文化符号提及 11、制作诟病 7、文化比较 6。已编码的 38,566 条上，编码器少标最多的是文化符号提及 3,740，多标最多的是知识补证 239、传统美学褒扬 196、实践印证 111。古今适配讨论在这 38,566 条上的多标是 0、少标是 69。页面上的 38,566 仍是规则计数。同一批 1,500 条缺口里，编码器标中 171 条；字符模型标中的 292 条仍然有效，两套次数各算各的。

同一主模型另有 136 个种子只训练、不再做全量前向。137 次的银标宏平均 F1 在 0.701 到 0.909，中位 0.802；核心句精确匹配在 0.727 到 0.970，中位 0.848；难句精确匹配在 0.125 到 0.500，中位 0.375。古今适配讨论这 137 次的中位仍是 0。hfl/chinese-macbert-large 种子 0 的银标宏平均 F1 为 0.936，核心句

32/33, 难句 4/8, 缺口 143/1,500, 训练 batch 为 8。hfl/chinese-roberta-wwm-ext 种子 0 为 0.816、核心句 27/33、难句 3/8、缺口 187/1,500。报告采用的仍是 base 种子 0。权重和边际清单留在训练机。

全量计数来自 2026-10-07 对本机 danmaku_out/tradition-hot 的 python -m wenmai analyze。清单 959 支, 其中 958 支已落盘, 1 支 (BV1zt411k7Es, 《国家宝藏》第二季第 3 集) 接口返回 -404, 没有当前池。958 支里 394 支当前公开池是空的: 页面弹幕计数仍在热门线以上, 播放器里现在拉不到弹幕。有字的池合计 833,104 条。上一轮在连续两段为空时就停, 片头空、后面有字的池被截掉; 这一轮按计划中的每一段都拉。《舞千年》第二章当时记成 0 条, 重拉后是 4,383 条。分布见附录。

有字的 564 支各是一颗星, 预渲染在 wenmai/results/starfield/。方向是该片六维命中先开方、再归一之后投到六条固定轴上, 稀有的维度仍能把星星从知识认知极拉开。大小是弹幕量的对数, 颜色是占优的一级维。没有落入六维的 30 支是靠近原点的暗星。页面上同一张图可以拖动旋转。

有字视频的六维星图, 斜向

全量读下来: 知识认知 29,836 条, 每万条 358.1 次; 传播思辨 414 条, 每万条 5.0 次, 没有一支片子以它为占优维。传播意愿 142 条里, 26.1% 来自同一支视频。点名昆曲时, 同一条落到审美鉴赏的密度是其他符号点名的 13.02 倍。按有字的 564 支视频放回重抽样 1,000 次, 这个倍数的区间是 6.83 到 19.60; 汉服落到传播思辨的点估计是 4.84 倍, 区间含 0。1,500 条规则没编码、也没拿去训练的弹幕里, 字符模型另标 292 条, MacBERT-base 种子 0 另标 171 条, 摘要只留各类次数。字符模型银标对照的宏平均 F1 为 0.879, 验证 885 条, 训练 3,731 条。MacBERT-base 种子 0 的银标宏平均 F1 为 0.798, 验证 461 条, 训练 4,155 条, 核心句 29/33, 难句 3/8。分组、曲线、停留和符号表在附录。

六、创新性与开放价值

1. 和常见做法的差别

常见弹幕分析把句子收成正负情感, 或只做词频。本作品的标签空间是文化接收的十七类, 并且把制作质量、观看体验、知识纠错和传承意向拆开。时间统计按视频等权, 突发也在单条视频内部计算, 避免头部视频决定整张图。

创新不在参数规模。创新在标签边界、可测试的操作化、以及模型和规则互相暴露错误的读法。

2. 开放成果

wenmai/ 以 MIT 发布。可复用的是码表、统计流程、可视化生成和 GPU 训练脚本。不可开放的是弹幕正文、由正文抽出的银标和据此训练的权重。

3. 别人怎么接着用

换一组视频时, 仍可用 --bvid 或改 collections.json 的检索词。十七类短语在 wenmai/codebook.py, 改完要让 python -m wenmai eval 的核心句精确匹配保持为 1, 否则就是把定义改破了。

4. 维护

页面已经把每万条密度、组内构成、空池、二级类抬升、停留换维、组间残差和六维星图画出来, 并可以按一支片子读出占优维、六维构成、相对该载体的抬升、点到的符号, 以及当前池是否为空。星图服务的是「这支片子的弹幕落在哪几维」, 不是装饰。规则没盖住的说法只把各类次数留在摘要里; 站得住的三条补进了短语和核心句, 核心句精确匹配仍为 1。「老师」「好看」「哈哈」「投币」仍不收进十七类。2026-10-08 已在 RTX 3090 24GB 上跑完主模型、大模型和另一种编码器的对照, 报告采用主模型种子 0。不计划把弹幕正文公开。

七、合规、安全与风险

1. 许可

Python 使用 PSF 许可，numpy 使用 BSD-3-Clause，本目录代码使用 MIT。可选的 PyTorch 使用 BSD，transformers 使用 Apache-2.0。hfl/chinese-macbert-base 的权重许可以 Hugging Face 上该模型卡片为准，只在使用者自己的机器上下载，不随仓库分发。

B 站播放器接口是网站服务，不是开源数据集。公开可访问不等于获得复制、训练、改编或再分发授权。因此正文、银标和权重不进入 git。

2. 数据与隐私

记录不含 midHash，不保存登录态。摘要只有计数、词表内符号和未编码句子的二字统计。写入仓库前看过这些二字，页面上出现的是「这个」「老师」「真的」「好看」这类普通词，不是完整句子。

3. AI 输出

规则会漏掉换了说法的句子，也会在短语过宽时误收。模型会在「为什么这么卡」这类观看体验上多标知识疑问。两者都不能当成某一条弹幕的最终编码。没有生成式接口，也就没有把用户文本送到外部模型的提示注入路径。代理生成的代码和段落已由测试和本机 eval 约束。

4. 权利边界

团队主张权利的是码表、程序和报告的表达。用户弹幕、平台接口和第三方模型权重的权利仍归原权利人。

5. 不适用的场景

不要用这套分数做内容处罚、作者排名或「文化自信高低」的结论。不要把难句上的低分解释成全量准确率。当前公开池会随时间变化，同一 BV 重拉可以和上次不同。

八、总结与展望

作品已经把十七类做成可测试的规则，并给出不依赖 GPU 的字符模型对照。核心句 33 条上规则精确匹配为 1，字符模型精确匹配为 0.879。MacBERT-base 种子 0 在同一批核心句上是 29/33，难句整句对上 3/8，银标宏平均 F1 为 0.798。这些编码器分数对照码表，页面计数仍是规则。难句说明换词之后规则和模型都会漏。当前公开池 833,104 条里，38,566 条至少落入一类（4.6%）；点名文化符号远多于辩论传承。394 支热门视频的当前池是空的。页面可以按片名读出占优维、六维构成、相对该载体的抬升和点到的符号；空池写明当前池是空的。有字的 564 支里，482 支的占优维是知识认知。传播思辨有 414 条，没有一支片子以它为占优维。1,500 条规则没编码的弹幕上，字符模型另外标中 292 条，MacBERT-base 种子 0 标中 171 条，摘要只留各类次数。

编码器对照已经落在本节和 wenmai/results/gpu-seed0.json。商业化不是本作品的目标。

九、附录

开源及第三方资源使用清单

资源	版本/来源	许可证	使用方式	关键义务或限制	团队自主部分	合规状态
Python	3.12, python.org	PSF	运行全部程序	保留许可声明	业务代码自写	已核验
numpy	本机已装, numpy.org	BSD-3-Clause	字符模型的向量和梯度	保留版权与许可声明	模型结构、损失和阈值自写	已核验
wenmai	本仓库	MIT	开放源码	保留版权与许可声明	全部自写	已核验
PyTorch	2.6.0+cu124, 可选	BSD	仅 GPU 脚本; 2026-10-08 在 RTX 3090 上跑过对照	保留许可声明	训练循环自写	已在对照中运行; 默认路径不加载
transformers	5.19.0, Hugging Face, 可选	Apache-2.0	加载编码器	保留 NOTICE, 标明修改	数据接口和多标签头的调用自写	已在对照中运行; 默认路径不加载
hfl/chinese-macbert-base	Hugging Face 模型卡片	以模型卡片为准	种子 0 为报告采用的对照, 权重不随仓库分发	不得无视模型卡片的使用限制	不修改权重文件本身	已用于对照; 权重不入库
hfl/chinese-macbert-large、hfl/chinese-roberta-wwm-ext	Hugging Face 模型卡片	以模型卡片为准	各一轮对照, 不作为采用分数	不得无视模型卡片的使用限制	不修改权重文件本身	已用于对照; 权重不入库
B 站公开播放器与搜索接口	api.bilibili.com	网站服务条款, 非开源数据	本地拉取当前公开池	公开可访问不等于再分发或训练授权	解码、去重、热门过滤自写	已核验限制; 正文不开放

运行说明

见 wenmai/README.md 与 danmaku/SCOPE.md。

赛题对照

赛题怎么读、六项评分各自对上作品的哪一块、当前弹幕分析的完整清单，见 wenmai/赛题解读与分析清单.md。技术报告仍按附件大纲写。规则计数以本附录和 summary.json 为准，编码器对照以 gpu-seed0.json 和 gpu-budget.json 为准。

参考文献位置

弹幕研究的书目在 research/catalog.md，仓库不收录论文正文。进度曲线只是借用「弹幕沿时间组织」这个研究问题，没有复现某一篇论文的实验。

全量分布

命令：python -m wenmai analyze danmaku_out/tradition-hot --list danmaku/lists/tradition-hot/_videos.json --out wenmai/results，再 python -m wenmai render。日期 2026-10-07。随机种子 0。页面是 wenmai/results/index.html，摘要同目录的 summary.json，三张星图在 wenmai/results/starfield/。这些文件

都不含弹幕原文。

项目	数
清单	959
已落盘	958
接口 -404，无当前池	1
当前池为空	394
弹幕	833,104
至少落入一类	38,566 (4.6%)
已编码里多类并中	1.7%
未编码里的纯笑声或气氛	3.3%
4 字及以内落入一类	2,690 / 214,650 (1.3%)
4 字以上落入一类	35,876 / 618,454 (5.8%)

一条弹幕可以同时落入多类，所以下表相加可以超过 38,566。

一级维度	条数	占全部弹幕	每万条
知识认知	29,836	3.58%	358.1
情感认同	4,801	0.58%	57.6
审美鉴赏	1,684	0.20%	20.2
作品评价	1,592	0.19%	19.1
传承意向	696	0.08%	8.4
传播思辨	414	0.05%	5.0

二级里最多的是文化符号提及 27,535，其次是文化记忆 2,290、文化自豪 2,136、传统美学褒扬 1,643、知识补证 1,306、知识疑问 1,183。审美辨析 41，古今适配讨论 69，文化比较 78。这三类规则写得窄，全量上稀少，不能把稀少读成「观众没有这些想法」。传播思辨 414 条，没有一支片子以它为占优维。传播意愿 142 条，出现在 67 支视频，其中 26.1% 来自同一支。读稀有类时要同时看条数和头部占比。

五组载体里，文物博物馆 306 支、空池 116、弹幕 359,685，知识认知是全库的 1.39 倍，情感认同 1.36 倍，传播思辨 1.34 倍。戏曲书画 262 支、空池 98、弹幕 264,731，审美鉴赏是全库的 2.25 倍。节庆民俗 133 支、空池 62、弹幕 70,107，作品评价是全库的 2.02 倍，情感认同是 1.28 倍。非遗技艺 135 支、空池 65、弹幕 37,364，传播思辨是全库的 2.10 倍，传承意向是 1.35 倍。典籍诗词 122 支、空池 53、弹幕 101,217，六维都低于全库，最高的知识认知是 0.70 倍。空池加总 394。有字的池是 190、164、69、70、71，合计 564，和星图上的星数一致。

视频等权的进度曲线上，移动最大的是知识认知，从片头四分之一的 3.60% 到片尾四分之一的 2.98%，约降 0.6 个百分点。情感认同从 0.57% 到 0.72%。其余维度的移动都不到 0.1 个百分点。问答邻近记下 12 条知识疑问。视频内突发 604 次，最多的是文化符号提及 247 次，其次是文化记忆 85、传统美学褒扬 59、文化自豪 50。传播意愿的头部视频占比 26.1%，赫芬达尔指数 0.084；其余各类头部占比都不超过 10%，不是单片决定的分布。

符号词表点名最多的是乾隆 4,088、李白 1,616、故宫 1,521、三星堆 1,378、越剧 1,313、汉服 1,012。人物类合计 8,327 次，书画戏曲 6,109，文物遗址 5,199。人物仍最高，其次已经是书画戏曲。词表里「千里江山」跟在「千里江山图」后面，全名仍先匹配。校名里的「大学」和官职里的「尚书」没有计进典籍。

点名某个符号时，同一条弹幕还会落到别的一级维。点名本身就会落入知识认知，所以对照是所有点到词表符号的弹幕，不是全库，也不把知识认知写成额外绑定。至少 20 次点名、倍数不低于 1.3、该维至少 8 条，才记下。这样写下的是：昆曲绑审美鉴赏，13.02 倍（17/418）；水袖绑审美鉴赏，10.36 倍（12/371）；越剧绑审美鉴赏，6.10 倍（25/1,313）；汉服绑传播思辨，4.84 倍（8/1,012）；京剧绑审美鉴赏，4.05 倍（9/712）。

这些倍数按有字的 564 支视频做了 1,000 次放回重抽样，种子 0，区间取 2.5% 到 97.5% 分位。空池不在抽样框里。昆曲的审美倍数落在 6.83 到 19.60，1,000 次里 95.0% 仍不低于 1.3 倍且不少于 8 条。水袖是 4.34 到 20.18，85.6% 仍过线。越剧是 4.06 到 9.04，1,000 次都过线。京剧的倍数区间是 1.32 到 8.01，同时满足两条线的次数占 65.2%。汉服的区间含 0，只有 49.2% 的重抽样仍过线。点估计过线，不能读成这条绑定在换一批视频后仍然站得住。

弹幕形态以滚动为主（730,674），顶部 85,198，底部 16,286，高级 946。已编码弹幕的发送时刻按东八区，20 时 3,131 条、21 时 3,052 条、22 时 3,047 条，仍是晚间最多。

未编码残差里最常见的二字是「这个」「老师」「真的」「好看」。码表仍然不把「好看」「哈哈」收进六维。

有字的 564 支里，534 支至少落入一类，30 支是暗星。占优维是知识认知的有 482 支，情感认同 27，作品评价 15，审美鉴赏 9，传承意向 1。传播思辨没有一支片子以它为占优维，所以星图上这一极只有轴，没有成团的星。清单里 958 支都有一张单片卡片：占优维、六维条数、相对该载体的抬升、词表里点到最多的三个符号。空池 394 张不编造抬升，页面写明当前池是空的。

二级类里，至少 20 条且不低于全库 1.3 倍的：节庆民俗的制作认可 3.47 倍（188 条），古今共情 1.42 倍（47 条），学习意愿 1.39 倍（30 条），文化自豪 1.33 倍（239 条）。戏曲书画的传统美学褒扬 2.29 倍（1,194 条），古今适配讨论 1.69 倍（37 条），观看体验 1.48 倍（367 条），知识疑问 1.32 倍（496 条），制作诟病 1.30 倍（69 条）。文物博物馆的文化比较 1.69 倍（57 条），文化自豪 1.67 倍（1,539 条），传播意愿 1.61 倍（99 条），知识补证 1.48 倍（833 条），传承困境探讨 1.43 倍（165 条），文化符号提及 1.41 倍（16,768 条）。非遗技艺的传承困境探讨 2.51 倍（30 条），学习意愿 2.00 倍（23 条），制作认可 1.32 倍（38 条）。典籍诗词没有任何二级类同时跨过这两条线。

同一套 1,000 次视频重抽样里，区间下端仍不低于 1 的有：节庆民俗的制作认可 2.45 到 4.48，戏曲书画的传统美学褒扬 1.91 到 2.77、古今适配讨论 1.17 到 2.24、观看体验 1.25 到 1.70、知识疑问 1.16 到 1.47，文物博物馆的文化比较 1.32 到 2.12、文化自豪 1.46 到 1.95、传播意愿 1.13 到 2.02、知识补证 1.32 到 1.69、传承困境探讨 1.16 到 1.79、文化符号提及 1.23 到 1.57。下端低于 1 的是非遗技艺的传承困境探讨（0.99 到 4.71）、学习意愿（0.94 到 3.42）、制作认可（0.71 到 2.29），节庆民俗的古今共情（0.72 到 2.29）、学习意愿（0.75 到 2.25）、文化自豪（0.69 到 2.23），以及戏曲书画的制作诟病（0.96 到 1.69）。条数少，或集中在少数视频上时，点估计过线并不等于换一批片子仍然过线。

一级维度上，戏曲书画的审美鉴赏是 1.88 到 2.72，文物博物馆的知识认知是 1.23 到 1.54、情感认同 1.20 到 1.53、传播思辨 1.13 到 1.67，节庆民俗的作品评价是 1.51 到 2.43。非遗技艺的传播思辨是 1.04 到 3.67，传承意向是 0.84 到 2.02。节庆民俗的情感认同是 0.88 到 1.83。典籍诗词的点估计六维都低于全库；知识认知的区间是 0.57 到 1.04，传播思辨是 0.30 到 1.61。区间和点估计都写在 wenmai/results/resample.json。

停留只比较相邻次数不少于 30 的维度。知识认知停在原维 3,002 / 3,598（83.4%），离开时最多接到情感认同（276）、作品评价（151）和审美鉴赏（125）。情感认同停住 114 / 436（26.1%），有 262 次回到知识认知。作品评价停住 46 / 251（18.3%），有 148 次接到知识认知。审美鉴赏停住 46 / 214（21.5%），有 129 次接到知识认知。传承意向停住 5 / 49（10.2%）。传播思辨的相邻只有 18 次，不拿来比停留率。

组间残差先去掉功能词，再去掉只出现在不足 8 支视频、或被单支占了一半以上的二字。过滤之后，页面每组留下 z 最高的六个二字。文物博物馆是「太师」「守护」「千年」「博物」「五千」「下五」，其中「下五」是「上下五千年」的残片；戏曲书画是「老师」「云霄」「君君」「谢老」「一一」「好听」，其中「老师」出现在 130 支视频；典籍诗词是「实名」「名观」「老子」「仲尼」「万物」「读书」；非遗技艺是「非遗」「投币」「视频」「三连」「颜色」「传统」；节庆民俗是「舞蹈」「河南」「验卡」「卫视」「体验」「振宇」。称呼、馆名残片、频道名和「好听」这类泛泛的好看都还在，所以这张图用来决定先不改十七类，而不是用来宣布新主题。戏曲书画相对其余组更突出的是「老师」。

字符模型在这份银标抽样上，对照规则的宏平均 F1 为 0.879（验证 885 条，训练 3,731 条）。模型多标最多的是文化符号提及（27），规则有而模型无最多的也是这一类（21）：符号靠词表，不靠字符模型记忆。这不是人工一致率。

另一批 1,500 条弹幕规则没有编码，也没有拿去训练。字符模型在上面标中 292 条。次数最多的是文化符号提及 100、传统美学褒扬 35、学习意愿 21、知识疑问 20、实践印证 20。这是模型多标，不是人工金标。摘要和页面只留各类次数，不写原文。抽看之后，只把落在定义里的「讲得真好」「古代人也」「字幕不错」补进短语，并各补一条核心句。核心句精确匹配仍为 1。

同一批 1,500 条上，MacBERT-base 种子 0 标中 171 条：文化符号提及 49，古今共情 35，实践印证 19，制作诟病 16，知识疑问 12，制作认可 11，观看体验 10，传统美学褒扬 5，文化自豪 4，学习意愿 3，审美辨析 3，知识补证 2，传播意愿 2，文化记忆 1。传承困境探讨、古今适配讨论、文化比较为 0。银标验证集上，模型多标的非零次数是文化符号提及 12、传统美学褒扬 5、实践印证 4、观看体验 3、古今共情 3、学习意愿 2、知识疑问 1、文化自豪 1、文化记忆 1、传播意愿 1；规则有而模型无的非零次数是文化符号提及 11、制作诟病 7、文化比较 6、制作认可 5、古今适配讨论 5、知识疑问 3、实践印证 3、观看体验 2、知识补证 2、古今共情 2、文化自豪 1、审美辨析 1、学习意愿 1。各类 F1 是：制作认可 0.884，制作诟病 0.774，观看体验 0.889，文化符号提及 0.753，知识补证 0.944，知识疑问 0.920，古今共情 0.865，文化自豪 0.952，文化记忆 0.983，传统美学褒扬 0.923，审美辨析 0.889，传承困境探讨 1.000，古今适配讨论 0.000，文化比较 0.000，学习意愿 0.936，传播意愿 0.970，实践印证 0.881。137 次主模型里，审美辨析的中位是 0.667，文化比较的中位是 0.500，古今适配讨论的中位是 0。这是对照码表，不替换页面计数。