

第八届全球校园人工智能算法精英大赛 · 算法主题赛 · AI+开源

一类视频的弹幕简报

技术报告

团队名称：报名时填写

团队编号：报名时填写

作品名称：一类视频的弹幕简报

参赛方向：开源赋能的 AI 应用创新

作品形态：本地网页服务

日期：2026 年 9 月 30 日

按初赛材料的匿名要求，本报告不写学校名称、校徽和指导教师。

一、作品概述

1. 背景与问题

使用者是研究某一类视频的文化研究者和政策制定者。他们要看的是这一类观众弹幕怎样分布，而不是某一条视频里哪一秒人多。一条条阅读做不到。只画单条热度，也看不出人在说什么，更不能拿去和另一类对照。

作品给出的对象是一个类型的接收结构：有哪些说法、各自盖住多少条视频、沿片长怎样起伏、这一类里面哪些视频没有这句话、和另一个类型比是共享、错开还是各自独有。每条都能点回成员弹幕。工具供研究使用，停在描述。

2. 目标、方向与形态

申报方向「开源赋能的 AI 应用创新」，场景是文化传播。形态是运行在使用者自己电脑上的网页。核心功能是：读入两份由人划定的视频清单，在同一条片长百分比轴上画出数量和说法，导出结构表，并生成一段只引用表内数字的简报。

3. 核心亮点

说法有两层。词来自分词，用来看这一类在提什么。完整说法是去掉标点后的整条弹幕，用来看哪一句被原样刷过。书名号、逗号不同而剩下的字相同，算同一句，点开仍能看到原来的写法。只在一条视频里出现的单独列出，不写入类型结论。简报里的每个数都能在导出表里找到，由自动测试核对。

二、需求分析与总体方案

1. 需求

目标用户现在能用的，多是单条视频的热度、情绪曲线或词云。这些回答不了「这一类」。需求按优先级是：先把两条时间对齐到片长百分比；再把不同写法收成可以点回原话的说法；然后标出缺席和两个类型的四栏差异；最后让简报不能写出表里没有的数。

2. 总体方案

输入是两个 zip，每个 zip 是一个候选类型。脚本读每条弹幕的播放进度、正文和发送时间，以及每一 P 的片长。位置等于前面各 P 的片长之和，加上本 P 内的进度，再除以全片片长。数量层只计数，不做归纳。说法层用分词和整句规则归并。结构表记下覆盖、进入、高峰、退出、缺席、发送时间跨度和差异栏。网页读这张表，不在浏览器里另算一套数。

3. 可行性与成本

主路径不租 GPU，也不调用付费接口。分词用 jieba 0.42.1，在普通 CPU 上运行。本机对两份材料（25 条与 48 条视频，合计 198013 条弹幕）生成页面和结构表约 36 秒。开发过程使用了 Cursor 中的对话模型起草代码和文字。那个模型不是作品运行时。别人只安装 Python 和 jieba，就可以重跑。

三、AI 技术与开源资源

1. AI 在作品里做什么

人工智能在这里是中文分词：把一条弹幕切成词，使「悟空」从不同的整句里被收成同一个说法。整句层不靠模型，只去掉标点后比较整条弹幕。这样每一条说法都能列出成员弹幕，不需要再叫一次模型来解释它自己。

验证分两步。成员弹幕必须含这个词，或者去掉标点后与这句相同。简报里引号外的每个整数必须出现在结构表的某个整数字段里，引号里的原文必须是表里的说法或差异栏条目。两步都写成自动测试。

同义不同词没有合并。例如「悟空」和「大圣」仍是两个词。这一步要人看原文判断，代理打的标签不能当作核对答案。短文本主题和句向量没有进入这次运行。生成式模型不进运行时，也不负责给弹幕归类。

2. 开源与第三方资源

资源	版本 / 来源	许可证	用法与限制	状态
jieba, 分词库	0.42.1; GitHub tag v0.42.1	MIT	运行时分词。保留版权声明。未改其词典代码	已核 验
Python 标准库	本机 Python 3.12	PSF	读压缩包、写页面、起本地服务	已核 验
哔哩哔哩当前公 开弹幕	api.bilibili.com 公开接口拉下 的压缩包	不是开源数 据集	只在运行者机器上计数。正文不进公开仓库。公开可 访问不等于可以再分发	已限 定

句向量模型、BTM、AutoPhrase 列在资源清单里，供以后同一套验收使用。这次没有调用。hotclip 的代码不
并进。

3. 自主部分与权利边界

接收结构的字段、冻结的协议、三页、结构表、简报填空和自动测试由本仓库实现。jieba 是未修改的第三方
库。弹幕正文的权利不属于本团队，因此不随仓库分发。没有学校或实验室的既有成果要另作授权说明。报告
不出现指导教师姓名。

4. 和简单套用的差别

作品不是把通用对话模型接到弹幕上，也不是换一张词云的皮。开源分词被用在类型这一层：同一个词或同一
句要跨多条视频才进入结论，并带着进入、高峰、退出、缺席和另一类型的差异栏。这些字段都能点回原话，
也能由测试复核。

四、设计与实现

1. 使用方式

准备两个压缩包。格式见 briefing/清单格式.md。每个视频有一份 meta（含分 P 片长）和一份 jsonl.gz（含
progress_ms、content、ctime、page）。不读取发言者标识。

```
python -m briefing 类型一.zip 类型二.zip --out demo_out
```

写出 demo_out/index.html 和 demo_out/report.json。加 --serve 后在本机打开。页面三栏是类型、说法、
对照。

2. 写死的协议

这些数在看这次结果之前写入 briefing/protocol.py，跑完没有改。

规则	取值	页面上怎么说
片长等分	20	写成开头、片长的百分之几、片尾
高峰容差	1 段，即片长的 5%	两边最密相差不超过片长的 5%，记成位置 差不多
写入类型结 论	至少 2 条视频，且至少 5 次	不够的不进结论
词	2 到 8 个字，含汉字，去掉虚词表和同一个字连写	反复提到的词
完整说法	去掉标点后 4 到 18 个字，且整条弹幕就是这句	重复的完整说法
页面列出	每层 8 条，按盖住的视频数再按次数	其余仍在结构表的计数里
简报	每层每类最多 3 句；人多处全部写入；沿片长再留次数最多的 4 截，按时间写	只填表内已有的数
依据样本	每条说法最多 12 条原话	总数以次数为准

虚词表是语法和话语壳，例如「这是」「应该」「已经」。它不按句子立场删弹幕。同一个字连写，例如一串「哈」，不单独成说法，但这条弹幕仍计入数量曲线。表没有盖住全部话语壳，所以「一样」「以为」这类词仍可能出现。看到结果之后没有再改这张表。

3. 关键实现

数量曲线统计每一条能定位的弹幕，不管它长不长、是不是标点。缺进度的不进入位置。说法另外计算。一条弹幕里同一个词只计一次。一条视频里同一个说法只给覆盖加一。高峰取次数严格最大的第一处。中位数保留分数，不先砍成整数。并列的数量高峰都画出来，不在句子里挑一个胜者。

点开说法时，列出同一高峰容差内的其他说法，并给出最早和最晚发送时间的相隔天数。日期按北京时间显示。证据文本是原话，词或整句只是归并键。

完整说法再沿片长看每一截进度上哪一句最多。相邻进度上是同一句的，并成一截。人多的地方写那里哪一句最多，并写这句自己最密是不是同一处。类型页把列出的完整说法画成贴在轴上的流，厚度是该句在该位置的次数。词也按同样的流来画。点开一条说法时，图是贴在轴上的面积。

两个类型用同一套段数、门槛和容差。四栏是：两边都有且高峰相差不超过容差；两边都有但高峰错开；只在前一个类型；只在后一个类型。页面先放完整说法，再放词，并写明词层里残留的话语壳没有被删掉。

4. 开发过程中的模型

代码、测试和本报告的起草使用了 Cursor 里的对话模型。团队需要核对的是：协议没有在出结果后改段数和容差；简报数字来自表；类型名单仍是候选，没有代签。运行页面不连接该模型，也不把模型输出当作人工抽查。

五、成果与效果

1. 怎么打开

演示材料是两份候选清单，不是已经签字的类型：黑神话官方 25 条视频，原神前瞻特别节目 48 条视频。压缩包留在运行机器上，不进入仓库。命令见第四节。自动测试 `python3 -m unittest briefing.test_briefing`，10 项通过。测试覆盖四栏是否分开、标点变体是否并成一句、只在一条视频里的说法是否排除、简报整数是否来自表、人民万岁这类句子是否仍被计数，以及沿片长换句时人多处与说法高峰是否同一处。


2. 数量：单条热度回答不了这一类

黑神话官方共 31206 条弹幕，其中 31143 条能放上片长，63 条没有播放进度。这一类最密的地方在片长的 45% 到 50%，以及 65% 到 70%。按视频号排在最前的一条，最密在 25% 到 30%，和这一类不是同一个位置。

原神前瞻特别节目共 166807 条弹幕，其中 166697 条能放上片长。这一类最密在开头的 5%。排在最前的一条最密在 50% 到 55%，也和这一类不是同一个位置。


只看一条

清单里按视频号排在最前的是 BV11PcgzWEJp。只看清单里按视频号排在最前的一条，最密的地方在片长的25%到30%，和这一类不是同一个位置。这一条图的高低按它自己的最高点来画。



这一类放在一起

黑神话官方共有25条视频、31206条弹幕。弹幕最密的地方在片长的45%到50%，以及片长的65%到70%。细线是每一条视频，粗线是这些视频的中间水平。粗线高的地方，就是这一类通常比较热闹的位置。横轴是片子从开头到片尾。特别冲的细线会在图顶被截断，免得一条视频把整类压扁。



人多的地方在说什么

人多的地方在片长的45%到50%。那里反复出现的整句里「前方高能」最多。「前方高能」自己最密在片长的80%到85%，和人多的地方不是同一处。

人多的地方在片长的65%到70%。那里反复出现的整句里「阶段性成果」最多。「阶段性成果」自己最密也在片长的65%到70%。

沿片长换说法

横轴是片子从开头到片尾。色带贴在轴上往上叠，厚度是这句完整说法在那个位置出现的次数。下面一条色带标出哪一句在哪一截进度上最多。点色块能回到原话。




图 1. 上图是一条视频自己的数量，虚线是它最密的位置。下图细线是各条视频，粗线是中位数，虚线是这一类最密的位置。图下两句写人多的地方当时哪一句最多。

3. 说法：覆盖、起伏、缺席、依据

黑神话官方写入结论的词里，覆盖最广的是「游戏」（25 条视频都有，851 次，最密在片长的 15% 到 20%）、「悟空」（24 条，496 次，最密在开头的 5%，另外 1 条没有）、「神话」（23 条，554 次，最密在 80% 到 85%，另外 2 条没有）。原神前瞻里覆盖最广的是「可爱」（48 条，1697 次，最密在开头的 5%）、「原神」（48 条，1390 次，最密在 70% 到 75%）、「角色」（48 条，1179 次，最密在 35% 到 40%）。这些词从开头一直分布到片尾，高峰却不在同一个位置。词在类型页上同样叠成一条流。

人多的地方和说法自己的最密处可以分开。黑神话官方最密的两处里，片长的 45% 到 50% 反复出现的整句以「前方高能」最多，这一截里 13 次；这句自己最密在 80% 到 85%，和人多的地方不是同一处。片长的 65% 到 70% 以「阶段性成果」最多，这句自己最密也在这里。沿片长把相邻的同一句并成一截之后，简报留下次数最多的几截，再按时间写：从开头到片长的 10%，「猿神启动」在这一截里 43 次；65% 到 70%，「阶段性成

果」20 次；75% 到 85%，「人民万岁」59 次；90% 到片尾，「新年快乐」33 次。这些次数是这一截里的次数。

原神前瞻最密在开头的 5%，那里「三个纠缠之缘」最多，这一截里 62 次，这句自己最密也在开头的 5%。简报里按时间写下的几截是：片长的 30% 到 40%，「山高狐狸野八重是我姐」129 次；70% 到 75%，「原神牛逼」97 次；75% 到 80%，「第五人格启动」156 次；95% 到片尾，「海灯节快乐」102 次。页面把每一截都列出来。




图 2. 色带贴在片长上，厚度是这句完整说法在该位置的次数。下面一条色带标出哪一句在哪一截进度上最多。灰色是没有画进上面这几句里的句子。字能放下才写在色带上，其余写在图下。

完整说法比词更接近「哪一句被刷了」。「正片开始」在黑神话 8 条视频里出现 19 次，最密在 55% 到 60%；在原神 30 条里出现 107 次，最密在 60% 到 65%。两边高峰相差一格，按写死的容差记成位置差不多。「承包空屏」两边都有，但黑神话最密在 15% 到 20%，原神最密在开头的 5%，记成错开。「前方高能」黑神话最密在 80% 到 85%（6 条，43 次），原神最密在 90% 到 95%（26 条，155 次），相差两格，也记成错开。容差没有为了让这两句看起来相同而改。

只在黑神话官方达到门槛的完整说法有 89 句，页面按覆盖列出的包括「作词冯骥」（8 条，16 次，最密在 85% 到 90%）和「金猴奋起千钧棒玉宇澄清万里埃」（7 条，27 次，最密在 80% 到 85%）。只在原神前瞻达到的有 877 句，例如「她真好看」（24 条，92 次，最密在 15% 到 20%）和「天动万象」（22 条，77 次，最密在 90% 到 95%）。

归并能点回原话。「狼神启动」这 5 条视频、80 次里面，依据样本同时有「狼神,启动！」和「狼神,启动！」。「阶段性成果」在表里是去掉书名号之后的键，依据里仍是「《阶段性成果》」，2 条视频、55 次，最密在 65% 到 70%，发送时间跨度 1058 天。「悟空」和「大圣」没有并成一个词：前者 24 条视频、496 次，后者 20 条视频、330 次。

一类视频的弹幕简报

给文化研究者和政策制定者看某一类视频的观众弹幕：哪些词和短句在片子的什么位置出现，哪些视频里没有。只描述弹幕，不评价，也不给建议。

这些视频不算同一类，还没有人签字。词按分词归并，完整说法按去掉标点后的整条弹幕归并。同一个字连写的单独成说法。同义不同词没有合并。只在一条视频里出现的单独列出，不写入类型结论。

词取 2 到 8 个字。完整说法是去掉标点 4 到 18 个字，并且整条弹幕就是这句。至少 2 条视频、5 次，才写入这一类的结论。两边最密相差不超过片长的 5%，记成位置差不多。

类型

说法

对照

[返回说法列表](#)


黑神话官方

正片开始

「正片开始」在 25 条视频里，有 8 条出现过，一共 19 次，另外 17 条里没有。从片长的 25% 一直到片尾都能看到这句，最密在片长的 55% 到 60%。

这些原话最早和最晚相隔 1973 天。日期是北京时间。

同一处最密的还有：踏平坎坷成大道（最密在片长的 55% 到 60%）、法天象地（最密在片长的 55% 到 60%）、敢问路在何方（最密在片长的 60% 到 65%）、虎力大仙（最密在片长的 60% 到 65%）、唢呐一响（最密在片长的 60% 到 65%）、敢问路在何方路在脚下（最密在片长的 60% 到 65%）、唢呐一响上台领奖（最密在片长的 60% 到 65%）、金蟾子我又赢了（最密在片长的 50% 到 55%）。



依据弹幕

- BV11PcgzWEJp · 片长的 80% 到 85% · 2026-02-10 · 正片开始
- BV11PcgzWEJp · 片长的 85% 到 90% · 2026-02-10 · 正片开始

图 3. 说法页把这一句画成贴在轴上的面积，虚线是它自己最密的位置。页上同时有覆盖、缺席、发送时间跨度、同一处最密的其他说法，以及带视频号、进度和北京日期的原话。不显示发言者。

只在一条视频里、因此不写入结论的，黑神话有 354 个词、104 句完整说法，原神有 472 个词、329 句。它们出现在说法页的末栏和结构表的单独计数里。

4. 四栏与简报

词这一层通过门槛的条目很多，因为门槛是写死的 2 条视频、5 次，原神有 48 条视频。四栏计数是：两边高峰接近的词 334 个，错开的 1609 个，只在黑神话的 870 个，只在原神的 8300 个。页面每种只列覆盖最广的 8 个，例子分别是「猴子」「游戏」「悟空」「旅行者」。完整说法的四栏是 8、16、89、877，例子是「正片开始」「承包空屏」「作词冯骥」「她真好看」。

对照黑神话官方和原神前瞻特别节目。位置差不多，是指两边最密的地方相差不超过片长的5%。斜线前是黑神话官方，斜线后是原神前瞻特别节目。

完整说法

两边都有，位置差不多（8）

- 正片开始
8 条视频里出现过，最密在片长的55%到60% / 片长的60%到65%
- 最喜欢的一集
5 条视频里出现过，最密在开头的5% / 开头的5%
- 这下听懂了
4 条视频里出现过，最密在片长的15%到20% / 片长的10%到15%
- 新年快乐
3 条视频里出现过，最密在片长的95%到片尾 / 片长的75%到80%
- 四大天王
3 条视频里出现过，最密在片长的80%到85% / 片长的75%到80%
- 金色传说
2 条视频里出现过，最密在片长的5%到10% / 片长的5%到10%
- 梦幻联动
2 条视频里出现过，最密在片长的5%到10% / 片长的10%到15%
- 世界名画
2 条视频里出现过，最密在片长的5%到10% / 开头的5%

两边都有，位置错开了（16）

- 承包空屏
8 条视频里出现过，最密在片长的15%到20% / 开头的5%
- 全体起立
7 条视频里出现过，最密在片长的95%到片尾 / 片长的70%到75%
- 前方高能
6 条视频里出现过，最密在片长的80%到85% / 片长的90%到95%
- 显卡的香气
5 条视频里出现过，最密在片长的15%到20% / 片长的75%到80%
- 蚌埠住了
4 条视频里出现过，最密在片长的20%到25% / 片长的65%到70%
- 芜湖起飞
4 条视频里出现过，最密在开头的5% / 片长的65%到70%
- 书接上回
4 条视频里出现过，最密在片长的85%到90% / 片长的65%到70%
- 来了来了
3 条视频里出现过，最密在开头的5% / 片长的80%到85%

只在黑神话官方（89）

- 作词冯骥
8 条视频里出现过，最密在片长的85%到90% - 16 次
- 金猴奋起千钧棒玉宇澄清万里埃
7 条视频里出现过，最密在片长的80%到85% - 27 次
- 斗战胜佛
7 条视频里出现过，最密在片长的70%到75% - 15 次
- 三界四洲
7 条视频里出现过，最密在片长的25%到30% - 14 次
- 中秋快乐
6 条视频里出现过，最密在开头的5% - 36 次
- 齐天大圣
6 条视频里出现过，最密在片长的90%到95% - 16 次
- 火钳刘明
6 条视频里出现过，最密在开头的5% - 15 次
- 既见未来为何不buy
6 条视频里出现过，最密在开头的5% - 9 次

只在原神前瞻特别节目（877）

- 她真好看
24 条视频里出现过，最密在片长的15%到20% - 92 次
- 牛蛙牛蛙牛蛙
23 条视频里出现过，最密在片长的20%到25% - 56 次
- 天动万象
22 条视频里出现过，最密在片长的90%到95% - 77 次
- 直奔主题
21 条视频里出现过，最密在片长的75%到80% - 45 次
- 蹦蹦炸弹
19 条视频里出现过，最密在片长的60%到65% - 41 次
- 非常简单
16 条视频里出现过，最密在片长的80%到85% - 52 次
- 搞妖舞舞
16 条视频里出现过，最密在片长的25%到30% - 38 次
- 开幕雷击
15 条视频里出现过，最密在片长的5%到10% - 49 次

下面是分出来的词。虚词表没有盖住全部说话用的架子，这些词仍留在计数里，没有按内容删掉。

词

两边都有，位置差不多（334）

- 猴子
23 条视频里出现过，最密在片长的70%到75% / 片长的70%到75%
- 注意
22 条视频里出现过，最密在片长的5%到10% / 片长的10%到15%

两边都有，位置错开了（1609）

- 游戏
25 条视频里出现过，最密在片长的15%到20% / 片长的65%到70%
- 神话
23 条视频里出现过，最密在片长的80%到85% / 片长的60%到65%

只在黑神话官方（870）

- 悟空
24 条视频里出现过，最密在开头的5% - 496 次
- 猴哥
19 条视频里出现过，最密在片长的85%到90% - 250 次

只在原神前瞻特别节目（8300）

- 旅行者
48 条视频里出现过，最密在片长的10%到15% - 910 次
- 瓦特
48 条视频里出现过，最密在开头的5% - 778 次

图 4. 对照页先给完整说法的四栏。斜线前是黑神话官方的最密位置，斜线后是原神前瞻的最密位置。

这次运行把简报里引号外的整数逐个对回 report.json 的 table，没有对不上的数；引号中的说法都能在说法行或差异行里找到。结构表共 14217 行，其中包含全部入选说法，不只有页面上的 8 条。人民万岁在黑神话的表里仍是一条完整说法：2 条视频、69 次，最密在 75% 到 80%，发送时间跨度 27 天，差异栏为只在这一类。研究计数没有因为它的内容把它拿掉。若正式提交文本不摘录某一句，那是报告的取舍，不回头改这张表。

5. 还没有达到的

两份材料没有人签字确认「这就是同一个类型」。同义不同词没有人看原文抽查。3 到 5 分钟的界面录像还没有。因此本报告不把整卷写成满分。

六、创新性与开放价值

1. 从已有研究转来的层

目录里有 588 条相关记录，多数只读到题名和摘要注。下面只写已经打开过、并且真的落进这件作品的几项，不把目录规模写成阅读量。

- Ni 与 Coupé（2023）把影片切成等分片长，看主题沿时间的分布，并比较类型之间的差异。本作品保留百分比轴和类型差异，段数改成写死的 20，差异做成可点开的四栏，类型由使用者划定。
- VideoForest（2016）和 DanmuVis（2022）给出可探索的弹幕可视化摘要。本作品保留「点开能回到原话」，对象从单条视频改成一个类型，并先展示单条热度，让两者的差别能被看见。
- CoKnowledge（2025）沿进度组织时间同步的评论。本作品沿同一条轴组织说法，不建立知识图谱，也不识别发言者。
- Zhang 与 Ren（2024）用情感曲线形状聚类。本作品留下形状比较：细线偏离粗线，就是这一类内部不一致。情感曲线不是默认主图，避免被读成民意。

- Wang、Liu 与 Han (2020) 的知识发现服务在单条商品视频上做主题，并把观点分析留到以后。本作品把带依据的说法扩到一个类型。
- Lin 等 (2025) 的 BERT-SVM 会议页说明情感分类加主题是另一条路。本作品不把情感分类放进默认结果。

百分比轴、单条可视化和情绪曲线都已经有人做过。创新不依赖宣称这些是空白，而依赖评委能在说法流、缺席和四栏上核对的那一层。

2. 开放成果与复用

已在仓库中的是服务代码 `briefing/`、类型清单格式、自动测试、`requirements.txt` 和本报告。换两份同样格式的压缩包，同一条命令得到同格式的表和页面。弹幕原文不进仓库。仓库自身的许可证尚未单列，以免和以后可能加入的依赖冲突；当前运行时依赖 `jieba` 的 MIT 许可已写入《资源清单》。

维护上，段数、容差和入选门槛继续以协议文件为准。人签字的类型清单和人看原文的同义抽查完成之前，页面上的「还没有人签字」「同义不同词没有合并」保持不动。

七、合规、安全与风险

弹幕来自网站当前公开接口，不是一份允许任意再分发的开源数据集。本仓库保存爬取脚本和清单格式，不保存正文。报告里出现的原句是结构表中的说法和少量依据样本，用来让结果可核对，不是把语料再发布一遍。

不读取、不显示发言者。不把曲线写成民意，不生成政策建议。虚词表和「同一个字连写」只决定什么可以成为一个说法，不把弹幕从数量里删掉。内容敏感的句子只要达到门槛就留在表里。人民万岁即是一例。

分词会把有的套话切开，整句层用来补这一刀。话语壳没有被虚词表收完，词层的四栏计数因此偏大，页面用覆盖最广的 8 条和一句说明来提示。类型边界未签字时，不能把结果说成某一文化类型的定论。工具不宜用于识别个人、评价群体倾向或直接起草政策。

开发辅助模型的输出经过测试和这次对表核对。它不是运行时组件，也不替代人工抽查。

八、总结与展望

作品已经能对两份候选材料重跑出类型接收结构：数量的粗线和细线、贴在片长上的说法流、人多处在说哪一句、沿片长哪一句领着哪一截、覆盖与缺席、依据、同一高峰附近的其他说法、四栏差异，以及与结构表一致的简报。主路径没有使用 GPU。

尚未完成的是：两份由人签字的类型清单，人看原文判断同义不同词是否该合并，以及 3 到 5 分钟只拍界面的演示录像。这三件不做完，整卷不按满分计算。后续若做短文本主题或句向量，必须用同一套「能点回原话」的验收，不能另换一套不能复核的标签。

九、附录

1. 运行

依赖：`pip install -r requirements.txt (jieba==0.42.1)`。然后执行第四节的命令。测试不需要真实弹幕压缩包。

2. 参考文献

下列出处与仓库目录中的记录一致。除正文注明「打开过」的页面外，不把目录中的其余题名当成已读全文。

1. Ni, W., & Coupé, C. (2023). Time-synchronic comments on video streaming website reveal core structures of audience engagement in movie viewing. *Frontiers in Psychology*.
<https://doi.org/10.3389/fpsyg.2022.1040755>
2. Sun, Z., Sun, M., Cao, N., & Ma, X. (2016). VideoForest: Interactive visual summarization of video streams based on danmu data. SA '16. <https://doi.org/10.1145/3002151.3002159>
3. Chen, S., Li, S., Li, Y., Zhu, J., Long, J., Chen, S., Zhang, J., & Yuan, X. (2022). DanmuVis: Visualizing danmu content dynamics and associated viewer behaviors in online videos. *Computer Graphics Forum*.

<https://doi.org/10.1111/cgf.14552>

4. Zhang, Y., Wang, Y., Wang, X., He, C., Huang, C., & Ma, X. (2025). CoKnowledge: Supporting assimilation of time-synced collective knowledge in online science videos. CHI 2025.
<https://doi.org/10.1145/3706598.3713682>
5. Zhang, R., & Ren, C. (2024). Sentiment time series clustering of danmu videos based on BERT fine-tuning and SBD-K-shape. *The Electronic Library*. <https://doi.org/10.1108/el-10-2023-0243>
6. Wang, L., Liu, Z., & Han, H. (2020). Research on danmaku knowledge discovery service under computational communication. ICHSSR 2020. <https://doi.org/10.2991/assehr.k.200428.107>
7. Lin, Y., Zhang, X., Peng, G., He, X., & Deng, Y. (2025). Multidimensional danmaku analytics via a BERT-SVM fusion model. PMLR 278. <https://proceedings.mlr.press/v278/lin25a.html>

jieba 许可: Sun Junyi, MIT License, tag v0.42.1。